在 R Markdown 文档中使用中文

Hongwei Shi

2021 - 09 - 08

目录

	参考		1
		参考书目	
	1.2	R blogger 主页	2
	基本	21.48	2
	2.1	R 语言的历史	2
	2.2	R 语言,你值得拥有	2
	2.3	为什么要可视化?	3
	2.4	主要介绍内容	4
3	基础做图		
	3.1		4

1 参考资料

1.1 参考书目

- R for Data Science
- ggplot2: Elegant Graphics for Data Analysis
- $\bullet \;\; {\rm Advanced} \; {\rm R}$
- R Packages
- 现代统计图形
- 数据科学中的 R 语言
- R 语言教程

2 基本介绍 2

1.2 R blogger 主页

- Hadley Wickham
- 谢益辉
- 黄湘云

2 基本介绍

2.1 R 语言的历史

The History of R (updated for 2020)

- 1992: R development begins as a research project in Auckland, NZ by Robert Gentleman and Ross Ihaka
- 1993: First binary versions of R published at Statlib
- 1995: R first distributed as open-source software, under GPL2 license
- 1997: R core group formed
- 1997: CRAN founded (by Kurt Hornik and Fritz Leisch)
- 1999: The R website, r-project.org, founded
- 1999: First in-person meeting of R Core team, at inaugural Directions in Statistical Computing conference, Vienna
- 2000: R 1.0.0 released (February 29)
- 2000: John Chambers, recipient of the 1998 ACM Software Systems Award for the S language, joins R Core
- 2001: R News founded (later to become the R Journal)
- 2003: R Foundation founded
- 2004: First UseR! conference (in Vienna)
- 2004: R 2.0.0 released
- 2009: First edition of the R Journal
- 2013: R 3.0.0 released
- 2015: R Consortium founded, with R Foundation participation
- 2016: New R logo adopted
- 2017: CRAN exceeds 10,000 published packages
- 2020: R 4.0.0 released

2.2 R 语言, 你值得拥有

• R 是一个统计编程语言 (statistical programming)

2 基本介绍 3

- R 拥有顶尖水准的制图功能
- R 是免费的
- R 应用广泛,拥有丰富的库包,活跃的社区
- 统计学研究者的重要工具!

2019 年 8 月,国际统计学年会将考普斯总统奖(The Committee of Presidents of Statistical Societies Awards, 简称 COPSS 奖,被誉为统计学的诺贝尔奖) 奖颁给 tidyverse 的作者 Hadley Wickham 后,充分说明 R语言得到了学术界的肯定和认可,未来一片光明!

Hadley Wickham's Homepage,改变了R语言的人!



2.3 为什么要可视化?

- 看图片,往往能比表格传达出更多的信息,一图胜千言
- 可视化, "一半是科学、一半是艺术"。要做图, 更要做漂亮的图
- 但可视化只是一种手段,根据数据实际情况作展示才是重要的,并不是要追求酷炫,适合自己的才是最好的

3 基础做图 4

2.4 主要介绍内容

R base: graphicAdvanced: ggplot2交互图: plotly

3 基础做图

3.1 直方图

##

##

直方图(Histogram)是展示连续数据分布最常用的工具,它本质上是对密度函数的一种估计。

```
library(formatR)
usage(hist.default)

## ## Default S3 method:

## hist(x, breaks = "Sturges", freq = NULL, probability = !freq,

## include.lowest = TRUE, right = TRUE, density = NULL, angle = 45,

## col = "lightgray", border = NULL, main = paste("Histogram of", xname),
```

xlim = range(breaks), ylim = NULL, xlab = xname, ylab, axes = TRUE,


plot = TRUE, labels = FALSE, nclass = NULL, warn.unused = TRUE, ...)

- x 为欲估计分布的数值向量
- breaks 决定了计算分段区间的方法,它可以是一个向量(依次给出区间端点),或者一个数字(决定拆分为多少段),或者一个字符串(给出计算划分区间的算法名称),或者一个函数(给出划分区间个数的方法),区间的划分直接决定了直方图的形状,因此这个参数是非常关键的
- freq 和 probability 参数均取逻辑值(二者互斥),前者决定是否以频数作图,后者决定是否以概率密度作图(这种情况下矩形面积为 1)
- labels 为逻辑值,决定是否将频数的数值添加到矩形条的上方

我们以黄石国家公园喷泉数据 geyser 为例,展示了喷泉喷发间隔时间的分布情况。

```
par(mfrow = c(3, 2))
data(geyser, package = "MASS")
hist(geyser$waiting, main = "(1) freq = TRUE", xlab = "waiting")
hist(geyser$waiting, freq = FALSE, xlab = "waiting", main = "(2) freq = FALSE")
hist(geyser$waiting, breaks = 5, density = 10, labels = TRUE, xlab = "waiting", main = "(3) breaks
hist(geyser$waiting, breaks = 40, col = "red", xlab = "waiting", main = "(4) breaks = 40")
hist(geyser$waiting,
breaks = quantile(geyser$waiting, probs = seq(0, 1, 0.1)),
```

3 基础做图 5



直方图与密度曲线的结合:借助函数 density()可以计算出数据的核密度估计

```
hist(geyser$waiting, probability = TRUE, main = "", xlab = "waiting")
d <- density(geyser$waiting)
lines(d) # 添加密度曲线
polygon(c(min(d$x), d$x, max(d$x)), c(0, d$y, 0), col = "lightgray", border = NA) # 填充颜色
yend <- c(); brk <- seq(40, 110, 5)
for (i in brk) {yend <- c(yend, d$y[which.min(abs(d$x - i))])}
segments(brk, 0, brk, yend, lty = 3) # 在点对之间画线段
```

3 基础做图 6

